

28.09.2021

import numpy as np

Date :/...../.....

* $z = np.random.randint(2, 15, size=(5, 3))$

↓
5 satır, 3 sütun

* $z.shape$


→ (5, 3)

* $z.size$

→ 15

* $z = z.reshape(3, 5)$

↓
3 satır, 5 sütun



* $z = z.reshape(-1, 5)$

↓
3 satır, 5 sütun

* $z = z.ravel()$ # z 'yi tek boyut yapar.




$a = np.array([[1, 2, 3], [6, 7, 8]])$

* $a[1, 1] = 77$ → 77'ye dönüşür

* $a[:, 1] = 99$ → 1. column'dakiler 99 yapar.

* $np.empty((3, 3))$ ⇒ 3'e 3'lük 0 yazarız



* $np.random.rand(3, 3)$ # 0-1 arası değerler alır

* $np.random.randn(3, 3)$ # mean=0 olan değerler alır

* $np.random.randn(5, 10, size=(1, 3))$ varyans=1 (Normal distribution'i tutturabilmek için)
5-10 arası random değerler, 3'e 3'lük

Subject :

CONCATENATE

Date :/...../.....

```
my_arr = np.array([0,1,2,3,4,5,6,7,8,9]).reshape(5,2)
```

```
my_arr_1 = np.array([3,4,5,6,7,8,9,10,11,12]).reshape(5,2)
```

* `my_con = np.concatenate([my_arr, my_arr_1])`

↓
Alt alta yadı
(axis=0)

↓
İkisini birleştirdi ama
altına yadı.

* `my_con_1 = np.concatenate([my_arr, my_arr_1], axis=1)`

↓
Yan yana yadı
(axis=1)

↓
İkisini birleştirdi ama
satırlara ekledi.

* `my_con[1, [2,3]]` # 1. satırdan 2 ve 3. elemanı
al

* `my_con[[3,1], 2]` # 3. ve 1. satırdan
→ `([9, 5])` 2. satırdakileri getir.

* `my_con[0:2, 1:3]` } slicing ile
→ `array([[1, 3],
[4, 5]])`

* `my_con[:, [0,1]]` } fancy indexing ile
→ `array([[0, 4],
[2, 6],
[4, 8],
[6, 10],
[8, 12]])`

$a = \text{np.array}([[1, 2], [3, 4]])$

$b = \text{np.array}([[5, 6], [7, 8]])$

Subject :

Date :/...../.....

(*) $x = \text{np.stack}((a, b))$ # 2'ye 2'lik matrisi 3 boyutlu yaptık
X

(*) $x.ndim$
→ 3 (3 boyutlu)

(*) $x.shape$
→ (2, 2, 2)

(*) $y = \text{np.hstack}((a, b))$
($[[1, 2, 5, 6],$
 $[3, 4, 7, 8]]$)

Horizontal = yatay demek.
Yatayda eklemek yapar.

(*) $y = \text{np.vstack}((a, b))$
($[[1, 2],$
 $[3, 4],$
 $[5, 6],$
 $[7, 8]]$)

Vertical = dikeyde eklemek yapar.

Subject :

FILTERING → Çok kullanacağız.
Data setini bununla
temizleyeceğiz.

Date :/...../.....

```
array_1 = np.array([[1, 2, 3, 4],  
                    [5, 6, 7, 8],  
                    [9, 10, 11, 12]])
```

* bigger_than_5 = array_1 > 5 # Boolean çıktı olur.

* array_1[bigger_than_5] # 5'ten büyük olanlar
→ array([6, 7, 8, 9, 10, 11, 12])

* array_1[array_1 < 5] # 5'ten küçük olanlar
→ array([1, 2, 3, 4])

* array_1[(array_1 < 10) & (array_1 > 3)]
→ array([4, 5, 6, 7, 8, 9]) # Çoklu filtreleme

* array_1[(array_1 < 10) | (array_1 > 3)]
→ array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12])

Subject :

Date :...../...../.....

```
X = np.array([[1,2],[3,4]])  
y = np.array([[5,6],[7,8]])
```

AYNISI

⊛ `np.subtract(x,y)`

⊛ `x+y`

→ $\begin{pmatrix} [6,8], \\ [10,12] \end{pmatrix}$

⊛ `x-y`

$\begin{pmatrix} [-4,-4], \\ [4,4] \end{pmatrix}$

⊛ `np.multiply(x,y)`

(\downarrow `interp`)

↕ veya
 $x*y$

⊛ `np.divide(x,y)` veya `x/y`

⊛ `x/y`

⊛ `x**2`

⊛ `np.power(x,2)`

⊛ `np.sqrt(np.power(x,2))`

⊛ `np.log(x)` # Sağa meyilli? data sette kullanılır

⊛ `np.exp(x)` # Solu meyilli? data sette kullanılır

Subject :

Date :/...../.....

```
import pandas as pd
labels = ['x', 'y', 'z', 'h']
my_list = [5, 10, 15, 20]
arr = np.array([25, 50, 75, 100])
d = {'a': 10, 'b': 20, 'c': 30, 'd': 40}
```

⊛ `pd.Series(my_list, index=labels)`
↳ Kafana göre index atama
labels'ları index olarak kullan.

⊛ `pd.Series(arr)` ⊛ `pd.Series(d)`

→ 0 25
 1 50
 2 75
 3 100

→ a 10
 b 20
 c 30
 d 40

Serilerde Concatenate

```
ser = pd.Series([5, 10, 15, 100, 25, 30])
index = ['USA', 'Germany', 'France', 'UK', 'Turkey', 'Greece']
```

⊛ `ser.sort_values()` ⇒ Değerleri sıralar.
Burda 100'ü sona atar

⊛ `ser.sort_index()` ⇒ Indexlere göre sıralar.
Burda alfabetik sıralama yapar.

Label'lar Üzerinden Filtreleme

Subject :

Date :...../...../.....

* 'Turkey' in ser

→ True (Çünkü seride var.)

* 'Holland' in ser

→ False

* ser.isin([55]) ⇒ Value Üzerinden Filtreleme

* ser.keys() ⇒ Key'ler yani Ülke isimlerini listeler.

* ser.items

→ USA 5
Germany 15
...

for döngüsüyle her bir item'in
içine gireriz.

⇕ AYNISI

* for key, value in ser.items():
print(key, value)

DATA FRAMES

m = np.arange(1,10,2).reshape((3,5))

5 tane

df = pd.DataFrame(m, columns=['col1', 'col2', 'col3', 'col4', 'col5'])

Değerler ne
olacak?

Column'lar neler
olacak

Data Frame'e vermenin
yolları

* df.head(5)

* df.tail(2)

* df.sample(2)

→ Karışık 2 tane getirir.

08.10.2021

Subject:

```
import seaborn as sns
```

Date: 11/11/2011

```
df=sns.load_dataset("planets")  
df.head()
```

* df.method.value_counts()

⑧ `df.groupby('method')[['distance']].mean().sum()`

⑧ df.year.value_counts()

→ yıl bilgilerine baktık.

* df.groupby('year')[['orbital-period']].count()

Yıllara göre gruplayıp orbital-periyod'u saydık.

Subject :

Date :/...../.....

```
data = { 'Company' : ['Google', 'Google', 'Mic', 'Mic', 'face', 'face'],  
        'Person' : ['PB', 'Chandler', 'Ross', 'Joey', 'Rachel', 'Monica'],  
        'Sales' : [100, 140, 150, 99, 102, 110] }
```

⊛ df4 = pd.DataFrame(data)

⊛ my-map = { "Google" : "Goo", "face" : "fb" }

df4.Company = df4.Company.map(my-map)



Map data frame'e uygulanmaz.

İsimleri beşer
mediğin
değiştirildi

Replace "

uygulanabilir.

(Map sadece serilere, replace tüm dataya)

⊛ df4.Sales = df4.Sales.map(lambda x: x*100)

df4

Sales değerlerini 100 ile
çarpıktık.

REPLACE ile eski haline getirelim.

⊛ df4.Company.replace(to_replace='Goo', value='Google',
df4 inplace=True)

İsim tekrar

⊛ df4.replace({ "Goo" : "Google", "fb" : "face" })

→ Tüm dataya uygulayabiliyoruz.
Çünkü replace.

* `dup_df = pd.DataFrame([5,5,6,7,8,9],
[a,b,c,d,e,f,g])`
`dup_df`

* `dup_df.drop_duplicates()`



Aynı olan değerleri döndürmüyor.
 • Data büyük olduğunda hata vermesin diye kullanıyoruz. Data az değer getiriyor.

* `df.groupby('groups').sum()`

↓
 groups column'ına göre grupları,
 numeric columnları topla yazdır.

* `df.groupby('groups').aggregate(['mean', 'max', 'min'])`

↓
 Birden fazla değer yazacaksa
 liste içinde olmalı

`from scipy import stats`

* `df.groupby('groups').agg(['mean', 'min', 'max', 'count',
stats.mode])`

Subject :

Date :...../...../.....

① `df.groupby("groups").agg({'var1': ('min', 'max'),
var2': 'median'})`

var1'e min-max,
var2'ye median uygulanır

② `df[df.var1 > 50]`

var1'in 50'den büyük olanları getir

③ `df.groupby('groups').filter(lambda x: x['var1'].sum() > 80)`

var1'in 80'den büyük olan satırları şart koştuk

④ `df.groupby('groups').transform('mean')`

Mean'e dönüştür ve o gruba o mean değerini yaz dedik

⑤ `df.groupby('groups').transform(np.log)`

mean'deki gibi aynı grup ismine aynı değer yazmaz. Çünkü her sayının kendi log'unu alır

⑥ `df.groupby('groups').apply(np.mean)`

transform'daki gibi yazmıyorduk

⑧ If apply (np.sum)

! Apply Paine str almat, function ister.

⑨ $df2 = df1.iloc[:, 1:3]$

↓
Yeni bir abla-fratle d'f'ın bir kısmını
aldık

(*) df2.apply(np.sum, axis=1) → Apply'ı satır başına uygularız.

▼ Satır bazlı işlen yapmak için:

- Yukarıdan aşağı 0 , soldan sağa 1 olmalı

Concat

* `df3 = pd.concat([df1, df2], ignore_index=True)`


⑩ `df3.groupby('grp').apply(sum)`

A'ları topla A'ya yaz
B'leri " " " "

* df 3-groupby ('grp'). transform('sum') \rightarrow fark

▼ Genelde apply kullanacağız.

- Ama missing value doldurmada transform da kullanılır.



MERGE

(*) `pd.merge(col1, col2, on='id')`

↓
default \Rightarrow inner. Bu yüzden yazmadık.

id her iki data frame de olursa oradan merge etti ve sadece bir kere id sütunu yazdı.

inner \Rightarrow kesişimleri alır. Aynı column isimlerini kendisi otomatik değiştiriyor. (Sonuna hard ekliyor.)

(*) `pd.merge(col1, col2, how='outer')`

↓
Ortak olmayan satırları da getirir boş kalan yerleri NaN yapar

(*) `pd.merge(col1, col2, how='left')`

↓
Soldakinin kaç satırı varsa o kadar satır döner. Sağdakini boş almaz. (Soldakinin indexine göre)
Sağda boş kalan yere NaN yazar.

① `pd.merge(col1, col2, on=["id", "subject_id"])`

id ve subject_id üzerinde
birleştirme yaptı ve sadece
ortak olan varsa onu getirdi.

JOIN

① `col1.join(col2)`

col1'in satırlarını
bar aldı col2'de
değer yoksa NaN
yazdı.

! Join'in default'u = left

① `col2.join(col1, how="inner")`

How', özellikle belirttik çünkü defaultu
left.

PRE - CLASS Check Yourself - 4

(*) `df.dropna(thresh=3)`

↙
En az 3 NaN değere sahip olmayan sütunları
gerisini sil.

(*) `df.dropna(axis=1, inplace=True)`

↓
Drop all columns that have missing values.

(*) `df.groupby('column-name').std()`

↓
Bu column'a göre grupla std'ini al

(*) `df.groupby('column-name').describe()`

(*) `pd.merge(df1, df2, on='key')`

↙ Key sütunu üzerinden
merge yap

(*) `df1.join(df2)`

↙ `df2`'yi `df1`'e ekle.

(*) `def times3(x):`
`return x*3`

`df[['w', 'x']].apply(lambda x: x*3)`

	w	x
A	---	---
B	---	---
C	---	---
D	---	---
E	---	---

Subject :

Date :

* `df.pivot_table(values='column-name1',
index='column-name2',
columns='column-name3').head()`

columns	
column-name3	
index column-name2	
	Column-name1
	values

`\d` → Digitleri bulur '7' gibi

`\D` → Digit olmayanları bulur

`\w` → Harf, digit, underscore karakterleri bulur 'A7' gibi

`\W` → Harf, digit, underscore olmayanları bulur

`\s` → Bosluk, tab, newline 'ları bulur.

`\S` → Bosluk, tab, newline olmayanları bulur.

REGEX

`\d` → Any digit from 0 to 9.

`\D` → Matches any character which is not a decimal digit.
(Opposite of `\d`)

`\w` → Any letter, numeric digit or the underscore character.

`\W` → Any character that is not a letter, numeric digit or the underscore character.

`\s` → Any space, tab or newline character

`\S` → Any character that is not a space, tab or newline.
(Think of this as matching white-space characters.)

`import re` (Regex kütüphanesi)
`import pandas as pd`

SEARCH

`text = "A78L4IK"`

digitleri getir demek

`num = re.search('\d', text)`

`num`

→ `<re.Match object; span=(1,2), match='7'>`

`* num1 = re.search('\d\d', text)`

Digit istedik ilk digit
7 diyor ve 1. indexte diyor.

`* num1.group(0)`

→ 78

→ Bulduğumuz ilk digit grubu getirdi

! Search fonk. gruplar halinde pattern'leri bulur.

Subject :

Date :/...../.....

text = "8PM19MIN"

text'in içinde
ilk digit olanı getir.

(*) nondigi = re.search('\D', text)

print(nondigi)

→ P (Açıklanmış bir çıktı verdi.)

print(nondigi.group())

→ P Groupla açıklanmış olarak ne
istiyorum onu verir.

(*) text = "my phone number is 5556667777"

telno = re.search('d\d\d\d\d\d\d\d\d\d', text)

print(telno.group()) Tüm noları almak istiyorum.

→ 5556667777

▼ Aralıklı yazmak istersem :

telno = re.search('d\d\d\d d\d\d\d d\d\d\d\d')

print(telno.group())

→ 555 666 7777

* text = 'My phone number is 415-555-1212'

telno = re.search('\\\\d\\\\d\\\\d-\\\\d\\\\d\\\\d-\\\\d\\\\d\\\\d\\\\d', text)

print(telno.group(0))

→ 415-555-1212

⇒ group(1)
→ 415

group(2)
→ 555

group(3)
→ 1212

AYNISI

* ("\\\\d"*3 + "-" + "\\\\d"*3 + "-" + "\\\\d"*4, text)

→ 415-555-1212

with open('text.txt', 'w') as file : (YAZDIRILIK → 'w' ile)
file.write(text)

with open('text.txt', 'r') as file : (OKUTUK → 'r' ile)
txt = file.read

print(txt)

→ My number is 415-555-1212

İKİ FARKLI GRUPLAMA

Paranteze alına
gruplara
bölmek

* output = re.search(("(\\\\d\\\\d\\\\d)-(\\\\d\\\\d\\\\d-\\\\d\\\\d\\\\d\\\\d)", text)

print(output.group(1))

→ 415

print(output.group(2))

→ 555-1212

2 Parantez yapıp group(1), group(2) diye yazdırıldı

value = "0 1 , + 10 , o 100. 100000"

(*) output = re.findall('\d{1}', value)

print(output)

↳ value'nin içindeki tüm sayıları bul.

→ ['1', '1', '0', '1', '0', '0', '1', '0', '0', '0', '0', '0']

findall('\d{1}', value)

↳ süslü parantez içine yazılır.
1'li olan digitleri bul

(*) output = re.findall('\d{1,6}', value)

print(output)

→ ['1', '10', '100', '100000']

↳ 1'li? 2'li? 3'li? ... 6'li olanları getir dedik

! sub → deęisiklik yapar. (*
(replace gibi)

Subject :

Date :/...../.....

phone = "2004-959-559 # This is Phone Number:"

(*output = re.sub('D', '*', phone)

print(output) neyi ne ile deęistireceksin

→ 2004*959*559

↓ Digit olmayanları al aralara carpi koy

(*output = re.sub('d', '+', phone)

print(output)

→ + +

Special Characters

"[]" → A set of characters "[a-m]" → Bu aradaki karakterlerde herhangi biri olur.

"\" → Özel bir sequence varsa onu g sterir.

"." → Newline character dışında hepsi (Mesela digit ve letter istediğin sonrası önemli değil ne gelirse gelsin)

"^" → Bununla başlaın demek. "^hello"

"\$" → Bununla bitisin demek "word\$"

"*" → Her olmayabilir, birden fazla da olabilir.

"+" → Aradığın pattern 1 veya daha fazla olabilir.

"{}" → {} → 1'lik digitleri bul gibi
{} → 3'lik digitleri bul gibi

"|" → or demek

"()" → Sadece g rmek istediğini getirir. (Söyl k kullanacağız)

txt = "1 person against 100 people"

⊛ output = re.findall('\d+', txt)

print(output)

→ ['1', '100']

----- re.findall('\d*', txt)
print(output)

⊛ txt = "hello world"

output = re.findall('^he', txt)
print(output)

↓ he ile başlayanları getir.

→ ['hello']

⊛ output = re.findall('world\$', txt)

print(output)

↓ world ile bitenleri getir.

→ ['world']

- str.contains
- str.extract

Subject :

Date :/...../.....

`s = pd.Series(['a3', 'b4', 'c5', 'd'])`

* `s.str.contains("(\\d)")` → Digit içeriyor mu diye sorduk True-False döndürür.

`s.apply(lambda x: True if re.search("\\d", x) else False)`

s

0	a3
1	b4
2	c5
3	d

* `s.str.extract("(\\d)")`

	0
0	3
1	4
2	5
3	NaN


→ Sadece digit olanları getir

* `s.str.extract("(\\w)")`

	0
0	a
1	b
2	c
3	d

→ Harf, digit, underscore ları getir
(Neden rakamları getirmedi?)

↓
ANLAMADIM



Series kullanılan regex methodları ⇒ `str.contains`
`str.extract`

Subject :

Date :/...../.....

```
s = pd.Series(['a3aa', 'b4aa', 'c5aa'])
```

```
s.str.extract('(\w)(\w)(\w)')
```

	0	1	2
0	a	3	a
1	b	4	a
2	c	5	a

3 tane getir dedik
'\w' digitleri de alır. Sayılardan
nasıl kurtulurum?



```
s.str.extract('(\w)\d(\w)(\w)')
```

	0	1	2
0	a	a	a
1	b	a	a
2	c	a	a

Digit olanı atla, diğerlerini
al dedik bu yüzden
'\d'yi parantez içine
almadık.

! .extract ⇒ Dataframe döndürür.

! Regex ile temizlik yapıp veriden sadece istediğim
kısımları çekiyorum.

```
(*) result = s.str.extract('(\d\d|\d.\d)')
```

İki digit veya digit nokta digit olanları getir.
12 1.2

```
(*) result = s.str.extract('(\d\d|\d.\d|\d)')
```

2'li digit veya noktalı veya tekli digitleri al
2'li digit 2'li digit

↑
SINCE
↓

⊛ `a = s.str.extract('(\d+)\d+')`

Q	
0	40
1	38
2	
3	6.4

Bosluk olmayan
karakter bir
veya daha fazla
karakter

Bir veya daha fazla boşluk

Bunu yazmasak da
aynı sonuç

(*) result = s.str.extract('(\d+).(\d+)')

	0	1
0	06	2020
1	11	2020
2	10	2019
3	05	2022

* result = s.str.extract('(\\S+\\S+)')

①	
0	06/2020
1	11/2020
2	10/2019

```

(*) result = s.str.extract('(\\d{2})/(\\d{4})')

```

Ayay sonuq

$$\left((1 \{1\} 2 \{2\}) (1 \{2\} 3 \{3\}) \right)$$

4. 301 